

Εργασία Βιοπληροφορικής, εαρινό εξάμηνο ακαδημαϊκού έτους 2025-2026

Ημερομηνία παράδοσης: ημερομηνία εξέτασης του μαθήματος, ώρα 23:59

Η εργασία είναι ατομική και απαλλακτική. Ισχύει και για την εξεταστική Σεπτεμβρίου. Δεν θα γίνουν δεκτές εκπρόθεσμες εργασίες ή εργασίες που δεν θα παραδοθούν μέσω e-class.

Παραδοτέα μέσω της ενότητας εργασιών στο e-class:

α) η τεκμηρίωση της εργασίας σε ένα αρχείο `documentation.pdf`, στην πρώτη σελίδα του οποίου αναγράφεται το ονοματεπώνυμο του φοιτητή/φοιτήτριας και ο ΑΜ. Δεν θα βαθμολογηθούν εργασίες που δεν περιέχουν τεκμηρίωση **β)** τα αρχεία `source code` σε ένα συμπιεσμένο αρχείο με όνομα `source2026.zip` (ή `.rar` ή άλλη σχετική κατάληξη), και **γ)** οποιαδήποτε άλλα συνοδευτικά αρχεία η ομάδα κρίνει απαραίτητα σε ένα συμπιεσμένο αρχείο με το όνομα `auxiliary2026.zip` (ή `.rar` ή άλλη σχετική κατάληξη).

Θέμα

i) Δίνονται τα παρακάτω patterns από το αλφάβητο A, C, G, T: `pattern1=AGATTA`, `pattern2=ACTTTGCA`, `pattern3=AACTGGCAA` και `pattern4=CATTGAGT`. Σχεδιάστε και υλοποιήστε μία μέθοδο σύνθεσης συμβολοσειράς, η οποία λειτουργεί ως εξής: α) επιλέγει ένα έως τρία σύμβολα με τυχαίο τρόπο και τα τοποθετεί στην αρχή της συμβολοσειράς. β) Επιλέγει κάθε ένα από τα παραπάνω patterns μία φορά, με τη σειρά που αναγράφονται και αντικαθιστά το πολύ δύο σύμβολα σε τυχαίες θέσεις, είτε με ένα άλλο τυχαία επιλεγμένο σύμβολο (για κάθε θέση ξεχωριστά) είτε με την κενή συμβολοσειρά (διαγραφή συμβόλου). Ότι προκύπτει συνενώνεται με την υφιστάμενη έως εκείνη τη στιγμή συμβολοσειρά. γ) Προσθέτει ένα έως τρία τυχαία σύμβολα στο τέλος της συμβολοσειράς. Δημιουργήστε συνολικά 200 συμβολοσειρές με τον αλγόριθμο σύνθεσης. Διαλέξτε με τυχαίο τρόπο 20 συμβολοσειρές και τοποθετήστε τις σε ένα σύνολο `datasetA`, 140 σε ένα σύνολο `datasetB` και τις υπόλοιπες 40 σε ένα σύνολο `datasetC`.

ii) Σχεδιάστε και υλοποιήστε αλγόριθμο πολλαπλής στοίχισης για τις συμβολοσειρές του συνόλου `datasetA`. Για τη σύγκριση δύο συμβολοσειρών, υιοθετήστε αλγόριθμο καθολικής στοίχισης ο οποίος ορίζει ότι: η οριζόντια και η κάθετη μετάβαση προσθέτουν `gap penalty -α`, η τοπική ομοιότητα προσθέτει `score +1` και η τοπική ανομοιότητα προσθέτει `penalty -α/2`. Επίσης, δυνατοί πρόγονοι του κόμβου (i,j) είναι οι $(i-1,j-1)$, $(i,j-1)$, $(i-1,j)$. Εκτυπώστε το αποτέλεσμα της πολλαπλής στοίχισης. Αν το ΑΜ του φοιτητή/φοιτήτριας καταλήγει σε άρτιο ψηφίο τότε $\alpha=2$, αλλιώς $\alpha=1$.

iii) Με βάση το αποτέλεσμα της πολλαπλής στοίχισης κατασκευάστε HMM profile και ρυθμίστε τους σχετικούς πίνακες πιθανοτήτων. Εκπαιδεύστε το με τις συμβολοσειρές του συνόλου `datasetB` χρησιμοποιώντας `best-path` εκπαίδευση και συχνотικές εκτιμήσεις των πιθανοτήτων.

iv) Υπολογίστε τα `alignment scores` για τις ακολουθίες του `datasetC` χρησιμοποιώντας την `any-path` μέθοδο. Επίσης υπολογίστε τα `alignment scores` για 40 τυχαίες ακολουθίες και σχολιάστε τα αποτελέσματα.

Αποδεκτές γλώσσες υλοποίησης είναι οι Python και Matlab. Κάθε ερώτημα πρέπει να συνοδεύεται από τεκμηρίωση στο αρχείο `documentation.pdf`. Η λογοκλοπή οποιουδήποτε είδους οδηγεί σε μηδενισμό. **ΚΑΛΗ ΕΠΙΤΥΧΙΑ.**